



INSTITUTO FEDERAL
Rio Grande do Sul

Banco de Dados II

Algoritmos para operações algébricas

Prof. Dr. Edimar Manica

edimar.manica@ibiruba.ifrs.edu.br



Referência

- Referência
 - Título: Sistemas de Banco de Dados
 - Autores: Elmasri & Navathe
 - Edição: 6^a
 - Capítulo: Processamento de consulta, otimização e ajuste de banco de dados
 - Páginas: 456-489
 - Material adaptado dos slides do livro

Roteiro

- Algoritmos para ordenação externa
- Algoritmos para operações de SELEÇÃO
- Algoritmos para operações de JUNÇÃO
- Algoritmos para operações de Projeção



Diversos algoritmos para diferentes operações

- Ordenação externa
- Seleção
- Junção
- Projeção

Diversos algoritmos para diferentes operações

- **Ordenação externa**
- Seleção
- Junção
- Projeção

Algoritmos para ordenação externa

- **Ordenação externa:**
 - Refere-se aos algoritmos de ordenação que são adequados para grandes arquivos de registros armazenados no disco que não cabem inteiramente na memória principal, como a maioria dos arquivos de banco de dados
- **Algoritmo ordenação-intercalação (sort-merge) :**
 - Inicia ordenando pequenos subarquivos (**pedaços**) do arquivo principal e depois mescla os pedaços classificados, criando subarquivos classificados maiores, que, por sua vez, são mesclados



Ordenação-intercalação

6 5 3 1 8 7 2 4


<https://upload.wikimedia.org/wikipedia/commons/c/cc/Merge-sort-example-300px.gif>



INSTITUTO FEDERAL
Rio Grande do Sul

Ordenação-intercalação

These numbers indicate the order in which steps are processed



Diversos algoritmos para diferentes operações

- Ordenação externa
- **Seleção**
- Junção
- Projeção

Algoritmos para operações de seleção

- Exemplos:
 - (OP1): $\sigma_{SSN='123456789'}(EMPLOYEE)$
 - (OP2): $\sigma_{DNUMBER>5}(DEPARTMENT)$
 - (OP3): $\sigma_{DNO=5}(EMPLOYEE)$
 - (OP4): $\sigma_{DNO=5 \text{ AND } SALARY>30000 \text{ AND } SEX=F}(EMPLOYEE)$
 - (OP5): $\sigma_{ESSN=123456789 \text{ AND } PNO=10}(WORKS_ON)$



Algoritmos para operações de seleção

- Métodos de pesquisa para seleção simples:
 - S1 **Pesquisa linear** (força bruta):
 - Recupera cada registro no arquivo, e então testa se seus valores de atributo satisfazem a condição de seleção
 - S2 **Pesquisa binária**:
 - Se a condição de seleção envolver uma comparação de *igualdade* em um *atributo chave* no qual o arquivo está ordenado, a pesquisa binária (que é mais eficiente que a pesquisa linear) pode ser utilizada
 - Exemplo (OP1): $\sigma_{SSN='123456789'}(EMPLOYEE)$, se o SSN for o atributo de ordenação para o arquivo EMPLOYEE
 - S3a **Usando um índice primário**:
 - Se a condição de seleção envolver uma comparação de *igualdade* em um *atributo chave* com índice primário
 - Exemplo (OP1): $\sigma_{SSN='123456789'}(EMPLOYEE)$, se o SSN tiver um índice primário. Observe que essa condição recupera um único registro (no máximo)



Algoritmos para operações de seleção

- Métodos de pesquisa para seleção simples:
 - **S3b Usando uma chave hash:**
 - Se a condição de seleção envolver uma comparação de *igualdade* em um *atributo chave* com uma chave de hash
 - Exemplo (OP1): $\sigma_{SSN='123456789'}$ (EMPLOYEE), se o SSN tiver uma chave de hash. Observe que essa condição recupera um único registro (no máximo)
 - **S4 Usando um índice primário para recuperar vários registros:**
 - Se a condição de comparação for $>$, $\geq$, $<$, ou $\leq$ em um *campo chave* com índice primário, - por exemplo, $DNUMBER > 5$ em OP2 -, use o índice para encontrar o registro que satisfaz a condição de igualdade correspondente ($DNUMBER=5$), depois recupere todos os registros subsequentes no arquivo ordenado. Para a condição $DNUMBER < 5$, recupere todos os registros anteriores



Algoritmos para operações de seleção

- Métodos de pesquisa para seleção simples:
 - **S5 Usando um índice de agrupamento para recuperar vários registros:**
 - Se a condição de seleção envolver uma comparação de igualdade em um *atributo não chave* com um índice de agrupamento – por exemplo, DNO=5 em OP3-, use o índice para recuperar todos os registros que satisfazem a condição
 - **S6 Usando um índice secundário (B+ tree) em uma comparação de igualdade:**
 - Utilizado para recuperar um único registro se o campo de índice for uma chave (tiver valores únicos) ou para recuperar múltiplos registros se o campo de índice não for uma chave. Este também pode ser utilizado para comparações utilizando >, >=, <, or <=.

Algoritmos para operações de seleção

- Métodos de pesquisa para seleção conjuntiva (composta de várias condições simples ligadas pelo conectivo lógico AND)
 - **S7 Seleção conjuntiva usando um índice individual:**
 - Se um atributo envolvido em qualquer condição simples isolada na condição de seleção conjuntiva tiver um caminho de acesso que permita o uso de um dos métodos S2-S6, use essa condição para recuperar os registros e depois verifique se cada registro recuperado satisfaz as condições simples restantes na condição de seleção conjuntiva
 - **S8 Seleção conjuntiva usando um índice composto**
 - Se dois ou mais atributos estiverem envolvidos nas condições de igualdade na condição de seleção conjuntiva e um índice composto (ou estrutura hash) existe nos campos combinados – por exemplo, se um índice tiver sido criado na chave composta (ESSN, PNO) do arquivo WORK_ON para OP5 -, podemos usar o índice diretamente



Algoritmos para operações de seleção

- Métodos de pesquisa para seleção conjuntiva
 - **S9 Seleção conjuntiva por intersecção de ponteiros de registro:**
 - Se índices secundários estiverem disponíveis em mais de um dos campos envolvidos em condições simples na condição de seleção conjuntiva, e se os índices incluírem ponteiros de registro (em vez de ponteiro de bloco)
 - Cada índice pode ser usado para recuperar o conjunto de ponteiros de registro que satisfaz a condição individual
 - A intersecção desses conjuntos de ponteiros de registros gera os ponteiros de registro que satisfazem a condição de seleção conjuntiva, que são então usados para recuperar esses registros diretamente
 - Se apenas algumas das condições tiverem índices secundários, cada registro recuperado é testado ainda mais para determinar se ele satisfaz as condições restantes



Algoritmos para operações de seleção

- Resumo:

- Se uma **única condição** especifica a seleção, nós podemos apenas verificar se um caminho de acesso (índice) existe para o atributo envolvido na condição
 - Se um caminho de acesso existe, o método correspondente a esse acesso é usado; caso contrário, utiliza-se a pesquisa linear (força bruta)
- Para **condições de seleção conjuntivas**, se mais de um dos atributos envolvidos nas condições tem um caminho de acesso, a otimização da consulta deve ser feita para escolher o caminho de acesso que recupera menos registros na forma mais eficiente



Algoritmos para operações de seleção

- **Condições de seleção disjuntivas**
 - condições simples ligadas pelo conectivo OR
 - Mais difícil de processar e otimizar, pois os registros que satisfazem a condição disjuntiva são a união dos registros que satisfazem as condições individuais
 - Somente se houver um caminho de acesso em cada condição simples na disjunção é que podemos otimizar a seleção
 - Caso contrário, a pesquisa linear será aplicada
- Um SGBD terá à disposição muitos dos métodos já discutidos
- O otimizador escolhe o método de acesso com o menor custo estimado



Diversos algoritmos para diferentes operações

- Ordenação externa
- Seleção
- **Junção**
- Projeção

Algoritmos para operações de junção

- Junção (Equijunção, junção natural)
 - Junção em duas vias: uma junção em dois arquivos
 - Ex. $R \mid X \mid_{A=B} S$
 - Junções multivias: junções envolvendo mais de dois arquivos
 - Ex. $R \mid X \mid_{A=B} S \mid X \mid_{C=D} T$
- Exemplos
 - (OP6): $EMPLOYEE \mid X \mid_{DNO=DNUMBER} DEPARTMENT$
 - (OP7): $DEPARTMENT \mid X \mid_{MGRSSN=SSN} EMPLOYEE$



Algoritmos para operações de junção

- Métodos:
 - J1 **Junção de loop aninhado** (força bruta):
 - Para cada registro r em R (loop externo), recupere cada registro s de S (loop interno) e teste se os dois registros satisfazem a condição $r[A] = s[B]$.
 - J2 **Junção de único loop** (Usando uma estrutura de acesso para recuperar os registros correspondentes):
 - Se um índice (ou chave hash) existe para um dos dois atributos da junção — digamos, atributo B do arquivo S — recupere cada registro r em R (loop no arquivo R) e depois use a estrutura de acesso (índice ou chave hash) para recuperar diretamente todos os registros correspondentes s de S que satisfazem $s[B] = r[A]$.

Algoritmos para operações de junção

- Métodos:
 - **J3 Junção ordenação-intercalação:**
 - Se os registros de R e S estiverem fisicamente ordenados por valor dos atributos de junção A e B, respectivamente, nós podemos implementar a junção da maneira mais eficiente possível
 - Os dois arquivos são varridos simultaneamente na ordem dos atributos de junção, combinando os registros que possuem os mesmos valores para A e B.
 - Nesse método, os registros de cada arquivo são varridos apenas uma vez para combinar com o outro arquivo — a menos que A e B sejam atributos não chave, caso em que o método precisa ser ligeiramente modificado



Algoritmos para operações de junção

- Métodos:
 - J4 **Junção de partição-hash**:
 - Os registros de arquivos R e S são particionados em arquivos menores
 - O particionamento de cada arquivo é feito usando a mesma função hash h no atributo de junção A de R (para particionamento do arquivo R) e B de S (para particionamento do arquivo S)
 - Um único passo pelo arquivo com menos registros (digamos, R) cria hashes de seus registros para as diversas partições de R
 - Os registros que obtiverem a mesma chave de hash são agrupados em uma mesma partição (denominada **bucket de hash**)
 - Um único passo através do outro arquivo (no caso S) cria o hash de cada um de seus registros usando a mesma função de hash h usando em R
 - Identifica-se o bucket de hash de R correspondente (bucket de hash de R que contém os registros com a mesma chave de hash gerada para s)
 - Então compara-se cada registro s de S apenas com os registros de R que estão no bucket correspondente

Algoritmos para operações de junção

- Fatores que afetam o desempenho da junção
 - Espaço de *buffer* disponível na memória
 - Fator de seleção de junção
 - Fração de registros em um arquivo que será juntado com registros no outro arquivo
 - Quanto maior o percentual de registros do arquivo que são juntados, mais eficiente
 - Escolha de qual relação será utilizada no loop externo e qual será utilizada no loop interno
 - Mais informações no livro.



Diversos algoritmos para diferentes operações

- Ordenação externa
- Seleção
- Junção
- **Projeção**

Algoritmos para operações de projeção

$\pi_{\langle \text{lista de atributos} \rangle}(R)$

1. Se $\langle \text{lista de atributos} \rangle$ inclui uma chave da relação R , extraia todas as tuplas de R com apenas os valores para os atributos em $\langle \text{lista de atributos} \rangle$.
 2. Se $\langle \text{lista de atributos} \rangle$ não inclui uma chave da relação R , as tuplas duplicadas devem ser eliminadas dos resultados.
- Métodos para remover duplicatas:
 1. Ordenação
 2. Hashing

