



INSTITUTO FEDERAL
Rio Grande do Sul

Mineração de Dados

Visão Geral

Prof. Edimar Manica

edimar.manica@ibiruba.ifrs.edu.br



Fonte

- TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. Introdução ao Datamining: mineração de dados. Rio de Janeiro: Ciência Moderna, 2009. 900 p. ISBN 9788573937619.
- CASTRO, Leandro Nunes de; FERRARI, Daniel Gomes. Introdução à mineração de dados: conceitos básicos, algoritmos e aplicações. 1.ed. São Paulo, SP: Saraiva, c2016. 351 p. ISBN 9788547200985.
- AMARAL, Fernando. Introdução à ciência de dados: mineração de dados e big data. Rio de Janeiro, RJ: Alta Books, 2016. xv, 304 p. ISBN 9788576089346.



Roteiro

- Descoberta de conhecimento em BD
- Métodos de mineração de dados
- Métricas de avaliação
- Bases de dados



Descoberta de Conhecimento em Bases de Dados

- Processo de análise de grandes quantidades de dados para extração de conhecimento, utilizando técnicas de Inteligência Computacional para procurar relações de similaridade ou discordância entre dados, com o objetivo de encontrar padrões, irregularidades e regras, com o intuito de transformar dados, aparentemente ocultos, em informações relevantes para a tomada de decisão



Objetivo

padrões

úteis


Não
triviais



Exemplo de aplicação




Processo de DCBD



Fonte: [FAYAAD et al. 1996]

Seleção

- Escolher os dados a serem minerados
- Selecionar:
 - Fontes de dados, tabelas, atributos



Pré-processamento

- Assegurar a qualidade dos dados envolvidos
- Por exemplo:
 - Remover ruídos
 - Remover atributos nulos
 - Balancear classes

Instância	Nascimento	Profissão	Sexo
01	01/08/1998	Professor	F
02	02/07		F
03	03/07/1999		M
04	08/06/03		F



Transformação

- Transformar os dados de forma que os valores sejam:
 - Interessantes ao usuário
 - Aplicáveis aos algoritmos

Instância	Idade	Sexo
01	11	0
03	10	1
04	6	0



Mineração de Dados

- Encontrar padrões relevantes, úteis e não triviais
- Escolher o método e o algoritmo mais compatível com o objetivo da extração
- Configurar os parâmetros



Avaliação

- Identificar os padrões interessantes ao critério estabelecido pelo usuário
 - Novas iterações podem ser necessárias
- Definir o que fazer com o conhecimento obtido



Principais métodos

- Classificação
- Associação
- Agrupamento



Classificação

- **Objetivo:** identificar a qual classe um determinado registro pertence

Bom
pagador

Mau
pagador



INSTITUTO FEDERAL
Rio Grande do Sul

Classificação: exercício

- Instalar a ferramenta WEKA
 - <https://www.cs.waikato.ac.nz/ml/weka/downloading.html>
- Abrir a ferramenta WEKA
 - Explorer
 - Open File
 - emprestimo.csv
 - Classe: pagou
 - Algoritmo J.48



Associação

- **Objetivo:** identificar quais atributos estão relacionados



+



=



Associação: exercício

- Utilizar a base supermarket.arff do WEKA
- Remover os atributos: **total** e **vegetables**
- Rodar o algoritmo **a priori**
 - Número de regras = 50
 - Confiança = 0,8
- Analisar as regras geradas



Agrupamento

- **Objetivo:** identificar e aproximar registros similares



Agrupamento



Agrupamento: exercício

- Utilizar a base iris.arff do próprio WEKA
- Definir o atributo para avaliação: **class**
- Rodar o algoritmo SimpleKMeans
 - Definir 3 clusters



versicolor



setosa



virginica



Agrupamento exercício

- Visualize cluster assignments
 - X: petallength
 - Y: petalwidth
 - Color: class
- Observações
 - Iris-setosa está bem separada
 - As demais não
 - X significa que agrupou corretamente
 - Quadrado significa que agrupou “erroneamente”
- Problema dessa visualização:
 - Só visualizo duas dimensões, por isso parece estranho o erro



Avaliação

- Classificação
- Associação
- Agrupamento



Classificação

- Matriz de confusão

Classe predita			Classe real
a	b	c	
49	1	0	
0	47	3	
0	2	48	
			a = iris-setosa
			b = iris-versicolor
			c = iris-virginica

Classificação

- Matriz de confusão

Classe predita			Classe real
A	B		
VP	FN	A	
FP	VN	B	

$$Acurácia = \frac{VP + VN}{VP + VN + FN + FP}$$

Desbalan-
ceamento

$$Revocação = \frac{VP}{VP + FN}$$

+ acertos


$$Precisão = \frac{VP}{VP + FP}$$

- erros

$$F - measure = 2 \frac{Revocação * Precisão}{Revocação + Precisão}$$


Classificação

Número total de instâncias
que chegam no nodo folha /
número de instâncias
classificadas incorretamente



Classificação

Quantas instâncias foram classificadas corretamente?



Classificação

- Rodar o algoritmo J.48 para a base de dados iris.arff
 - Verificar a matriz de confusão e as métricas de avaliação
- Rodar o algoritmo Nayve Bayes para a mesma base
 - Comparar os resultados
- Rodar o algoritmo NayveNet para a mesma base
 - Comparar os resultados
- Rodar o algoritmo functions.MultiLazerPerceptron
 - Comparar os resultados

Olhar F-measure e o
número de instâncias
classificadas corretamente

Associação

registro	leite	pão	manteiga	cerveja
1	1	1	0	0
2	0	1	1	0
3	0	0	0	1
4	1	1	1	0
5	0	1	0	0

- Suporte
 - $\text{sup}(X)$ é a proporção de registros na base de dados que contém X
 - Ex: $\text{sup}(\{\text{leite}, \text{pão}\}) = 2/5 = 0,4$
 - Ex: $\text{sup}(\{\text{leite}, \text{pão}, \text{manteiga}\}) = 1/5 = 0,2$
- Confiança
 - $\text{conf}(X \Rightarrow Y) = \frac{\text{sup}(X \cup Y)}{\text{sup}(X)}$
 - Ex: $\text{conf}(\{\text{leite}, \text{pão}\} \rightarrow \{\text{manteiga}\}) = 0,2/0,4 = 0,5$



Associação: exercício

- Utilizar a base supermarket.arff do WEKA
- Remover os atributos: **total** e **vegetables**
- Rodar o algoritmo **a priori**
 - Número de regras = 50
 - Confiança: 0,8
- Analisar a confiança das regras geradas



Agrupamento

- Ex 01:
 - Utilizar a base iris.arff do próprio WEKA
 - Definir o atributo para avaliação: **class**
 - Rodar o algoritmo SimpleKMeans
 - Definir 3 clusters
 - Anotar o número de instâncias agrupadas incorretamente
- Ex 02:
 - Utilizar a base iris.arff do próprio WEKA
 - Definir o atributo para avaliação: **class**
 - Rodar o algoritmo EM
 - Definir 3 clusters
 - Anotar o número de instâncias agrupadas incorretamente



Bases de dados

- <http://www.bigdatabusiness.com.br/6-bases-de-dados-gratuitas-para-mineracao-estudos-e-testes/>



Exercícios

- Explorar as demais bases de dados do WEKA

